Google BERT 模型解析及实验探索

追一科技 · 潘晟锋

ZHUIYI

BERT是什么

- BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

- BERT: **B**idirectional **E**ncoder **R**epresentations from **T**ransformers.

- BERT是
  - 预训练
  - 双向的编码表征
  - 深度transformer结构
  - 以语言模型为训练目标

大纲

- Part 1 语言模型简介
  - 文本表征
  - 语言模型
  - 深度学习与语言模型

- Part 2 BERT解析
  - BERT的基本结构
  - 模型模块详解
  - 源码中的细节

- Part 3 应用
  - 如何使用预训练模型
  - 实验心得

文本表征

- 文本表征是文本的“数字形式”表达：
  - 模型的运算需要数字
  - 模型的运算是连续的
    - 对于$x, y \in (0, 1)$，我们总可以找到介于x与y之间的值；
  - 自然语言是离散的
    - 对于$v \in \{$开心，很开心，非常开心$\}$，我们无法定义任意两个词之间的词；
  - 文本表征
    - one-hot, tf-idf...
    - word2vec, doc2vec, glove, fastext...
    - ELMo, GPT, BERT...

词向量

- 分布式假设
  - 相同上下文语境的词有相似的含义
- 词向量的弊端
  - 每个词一个固定表征
- 结合上下文的动态表征
  - ELMo, GPT, BERT等基于语言模型的表征

美国总统特朗普决定在墨西哥边境修建隔离墙

听说美国的那个川普总统要在墨西哥边上修个墙

同学你的川普挺带感啊

语言模型是什么

- 语言模型本质上是概率模型；
  - 在给定前文的基础上，从概率上预测接下来的内容；
  - 它的目标就是学会语言的“套路”；
  - 随着前文越详细，预测的目标越明确；

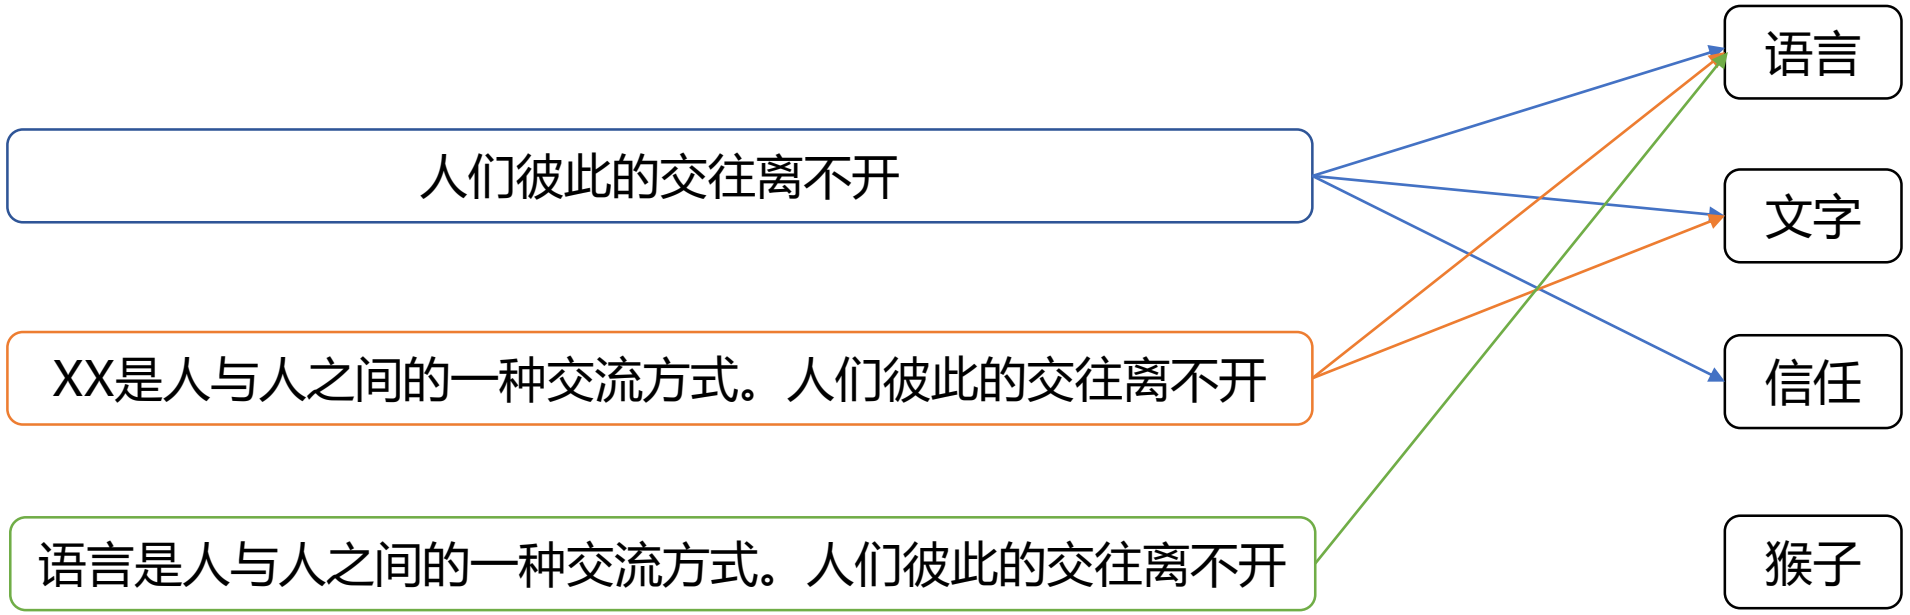

传统语言模型的问题

人们彼此的交往离不开语言

- N元语言模型
  - 过于短程的依赖
- 解决长程依赖的途径

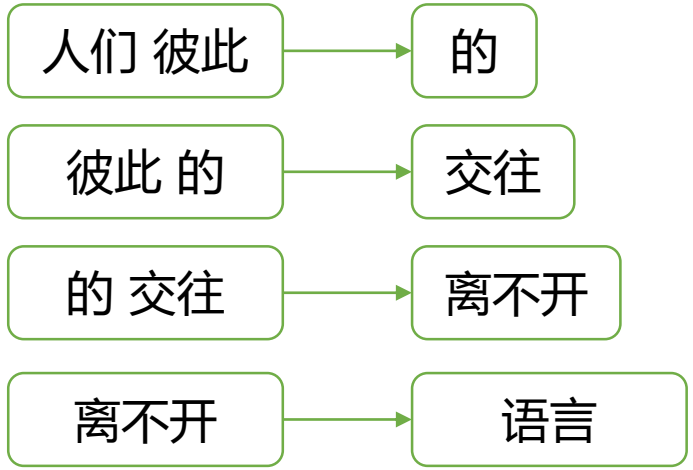

传统语言模型的问题

人们彼此的交往离不开语言

- N元语言模型
  - 过于短程的依赖
- 解决长程依赖的途径
  - RNN+LSTM, GRU

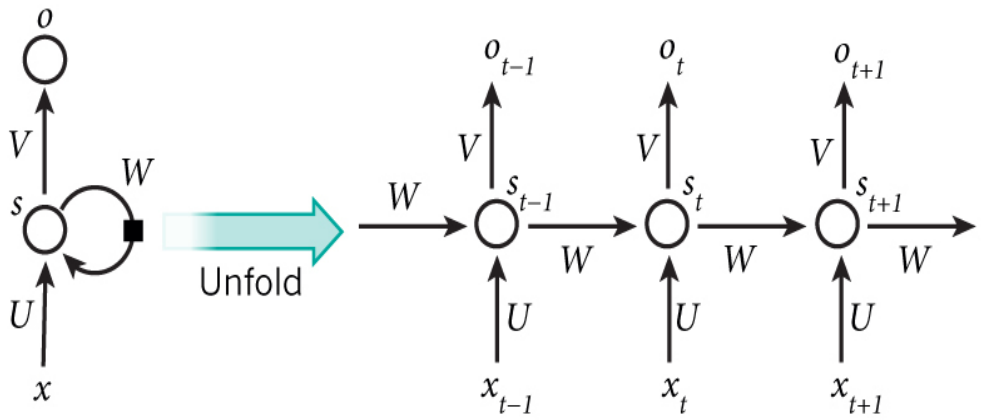

Long-Short Term Memory module: LSTM

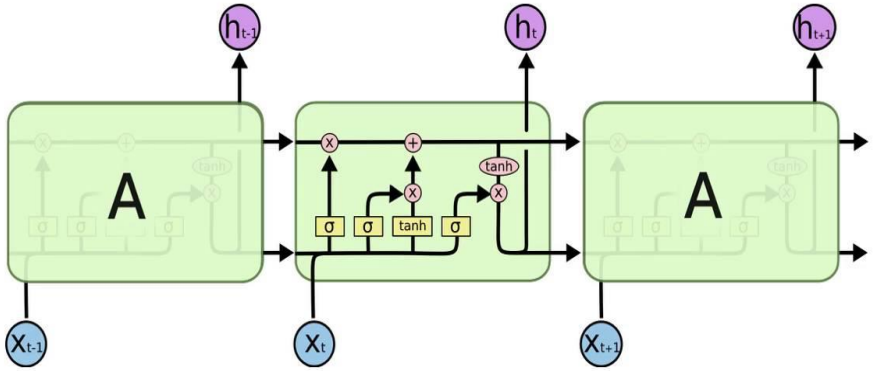

long-short term memory modules used in an RNN

Neural Network Layer | Pointwise Operation | Vector Transfer | Concatenate | Copy

http://colah.github.io/posts/2015-08-Understanding-LSTMs/ Eugenio Culurciello © 2016

传统语言模型的问题

人们彼此的交往离不开语言

- N元语言模型
  - 过于短程的依赖
- 解决长程依赖的途径
  - RNN+LSTM, GRU
  - Attention

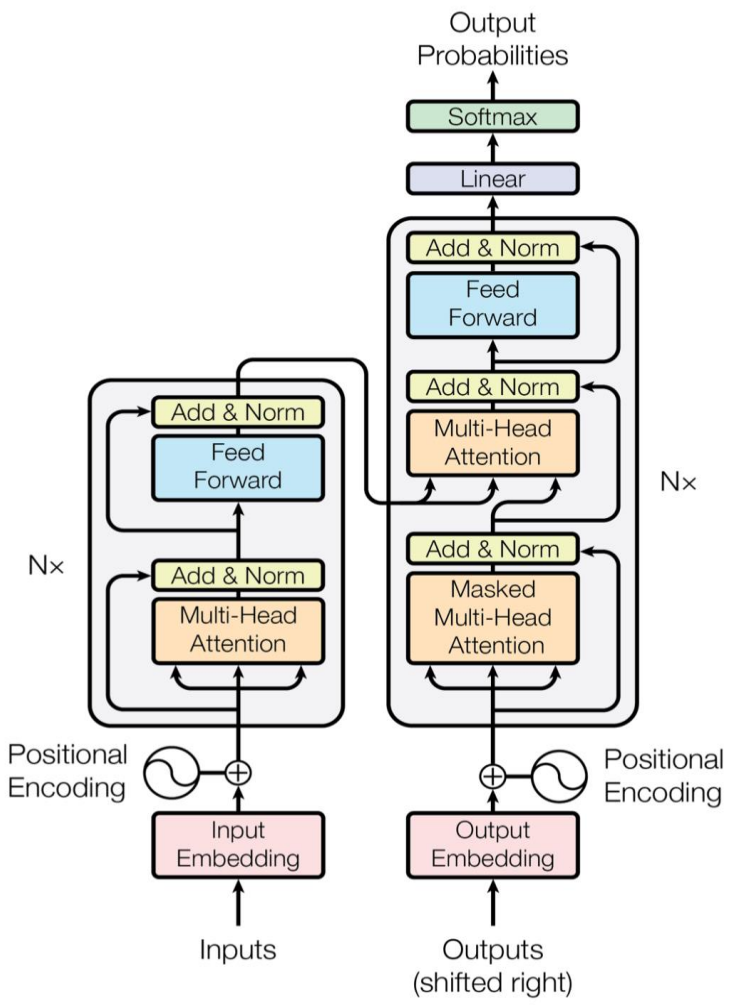

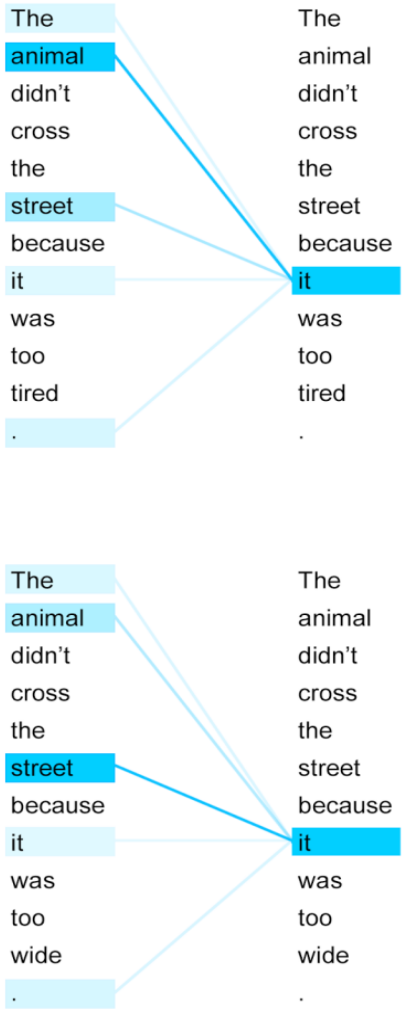

神经网络语言模型

人们彼此的交往离不开语言

- 单向RNN

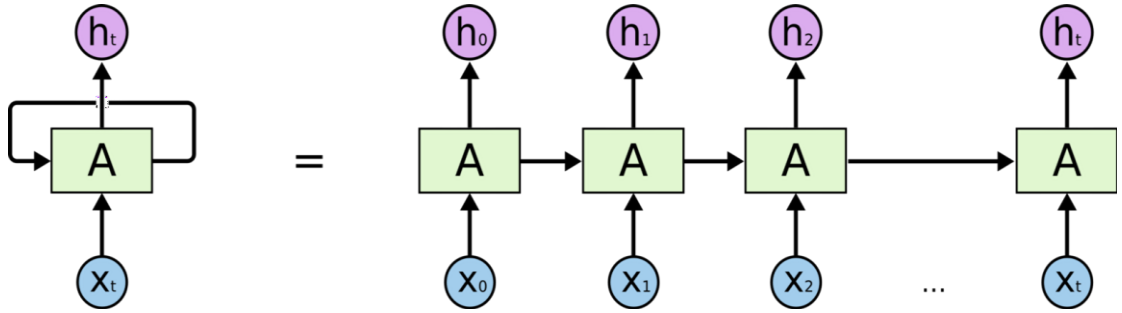

人们 → 彼此

人们 彼此 → 的

人们 彼此 的 → 交往

人们 彼此 的 交往 → 离不开

人们 彼此 的 交往 离不开 → 语言

神经网络语言模型

人们彼此的交往离不开语言

- 单向RNN
- 双向RNN

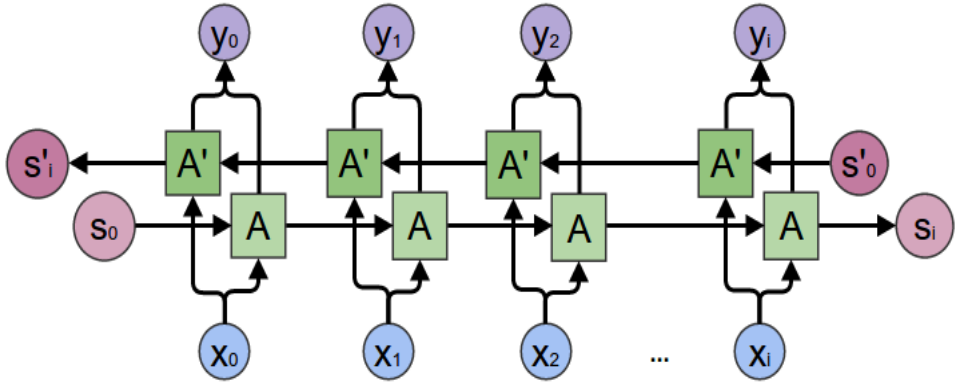

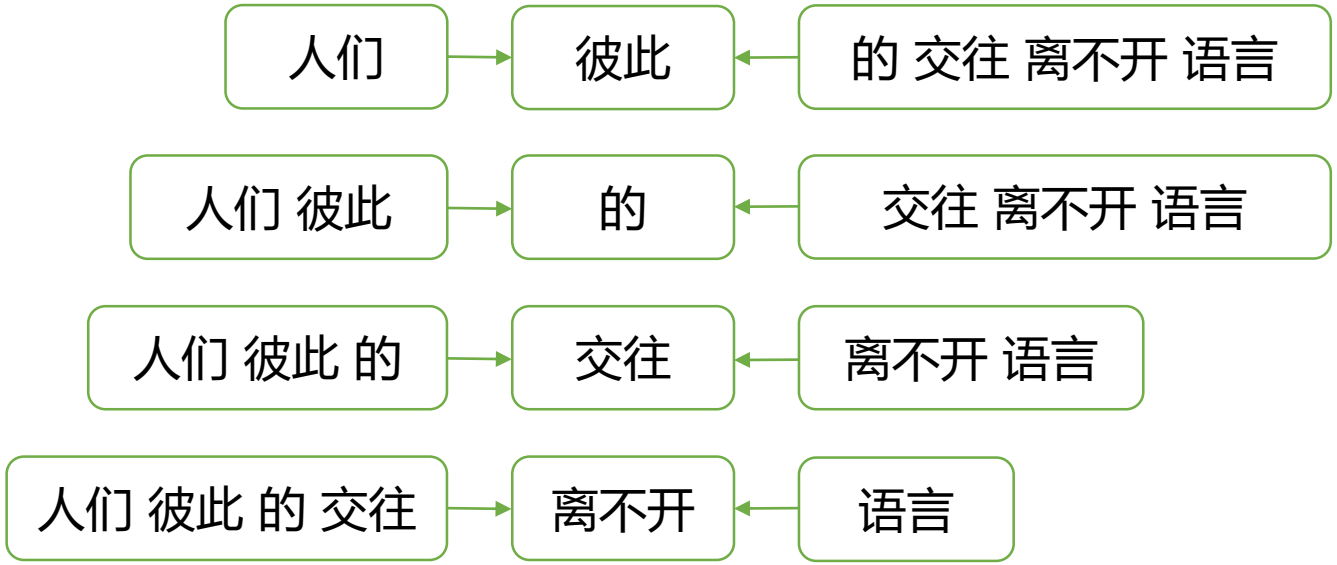

神经网络语言模型

人们彼此的交往离不开语言

- 单向RNN
- 双向RNN
- 单向Attention

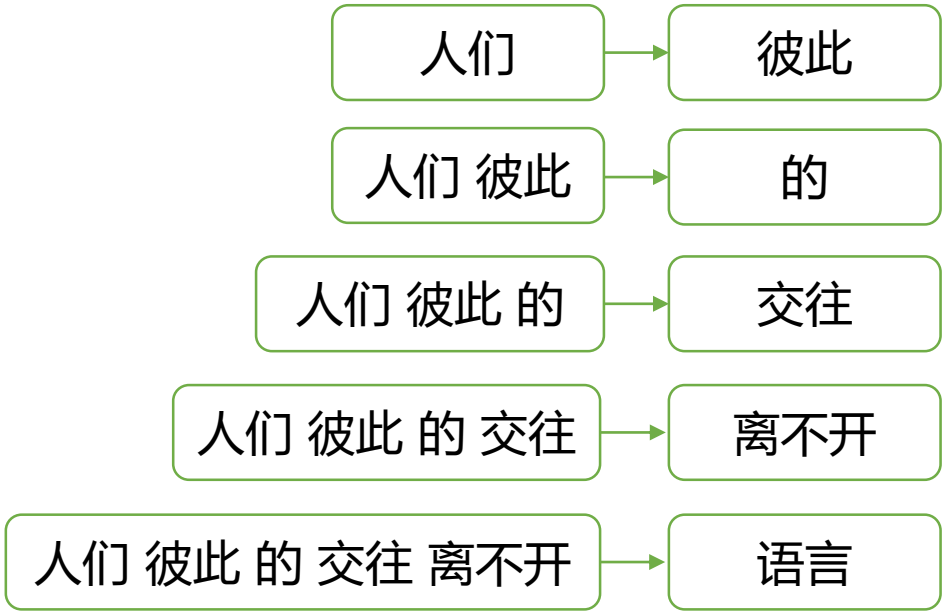

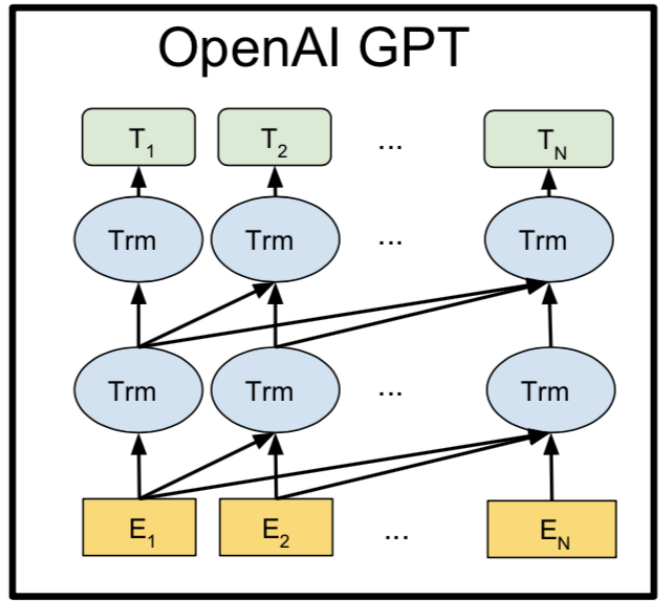

双向编码与网络深度的冲突

- 加深网络的层数可以带来更好的效果

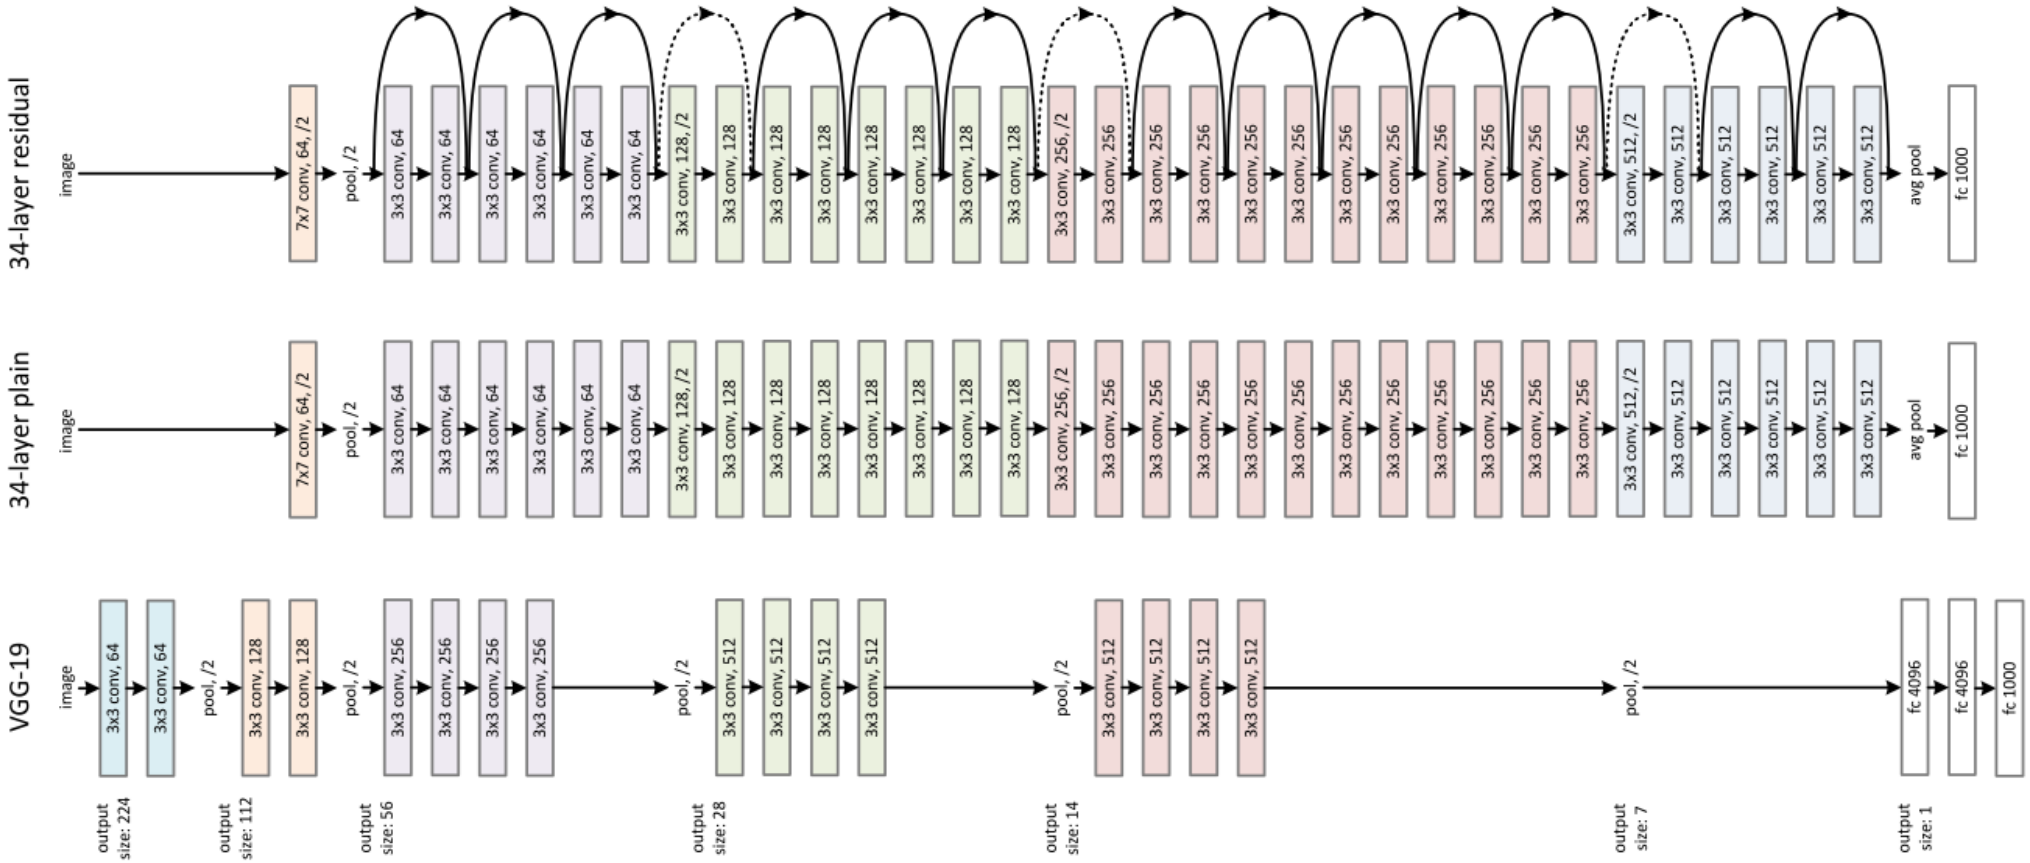

双向编码与网络深度的冲突

- 加深网络的层数可以带来更好的效果
- 深度的增加导致标签信息泄露

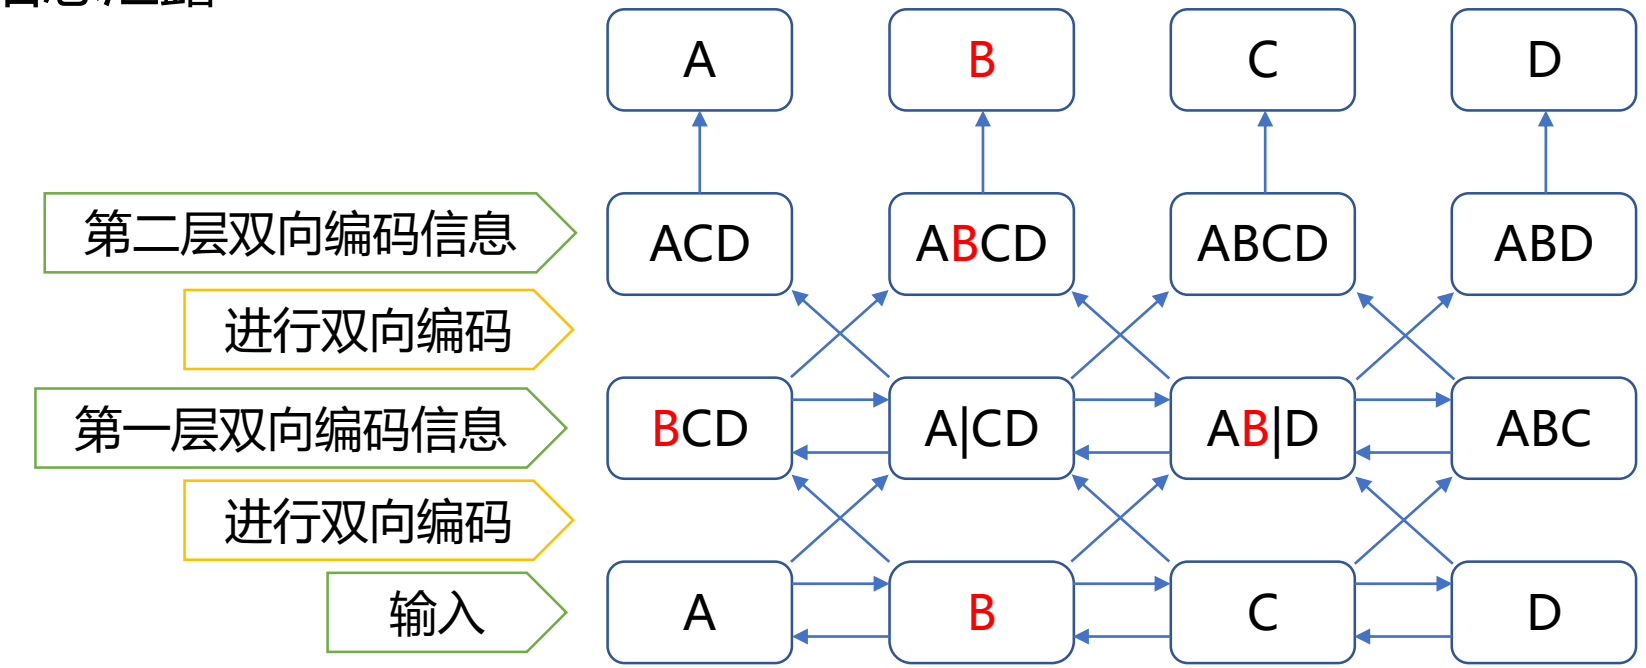

双向编码与网络深度的冲突

- 加深网络的层数可以带来更好的效果
- 深度的增加导致标签信息泄露
- 解决方式
  - 多层单向Rnn，独立建模(ELMo)

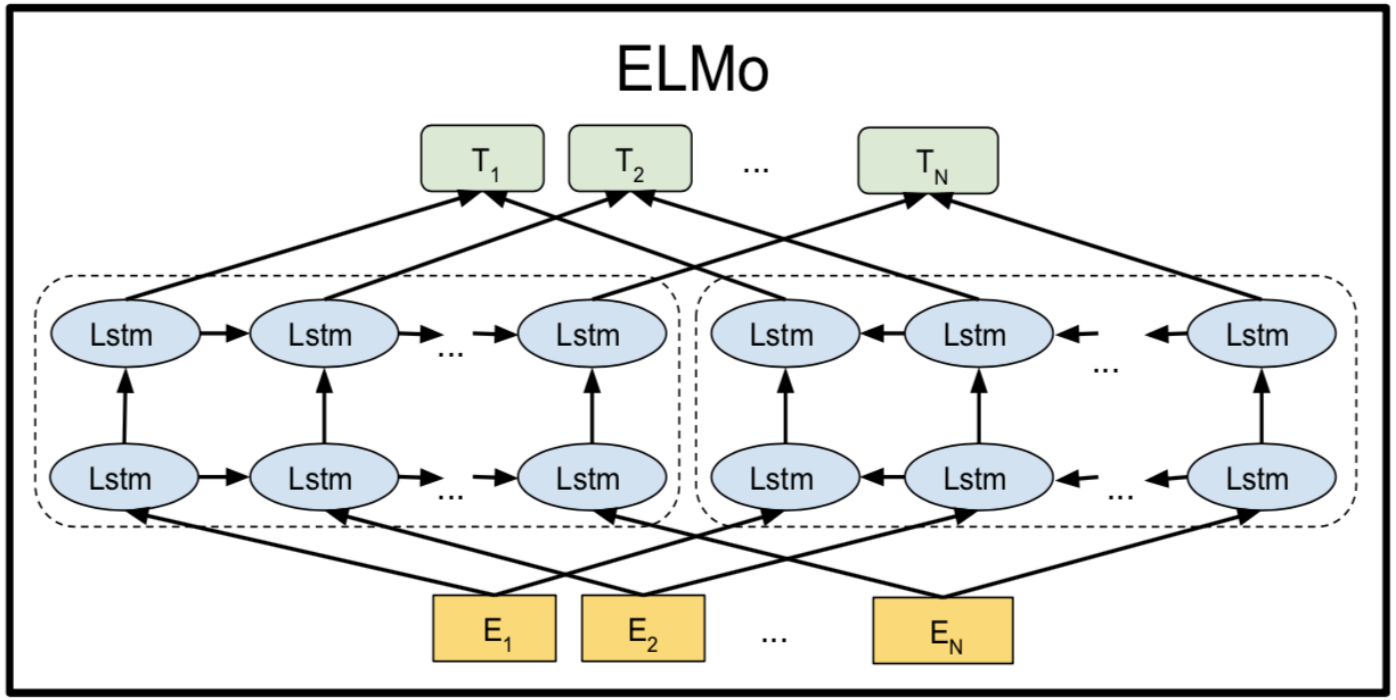

双向编码与网络深度的冲突

- 加深网络的层数可以带来更好的效果
- 深度的增加导致标签信息泄露
- 解决方式
  - 多层单向RNN，独立建模(ELMo)
  - Mask LM (BERT)

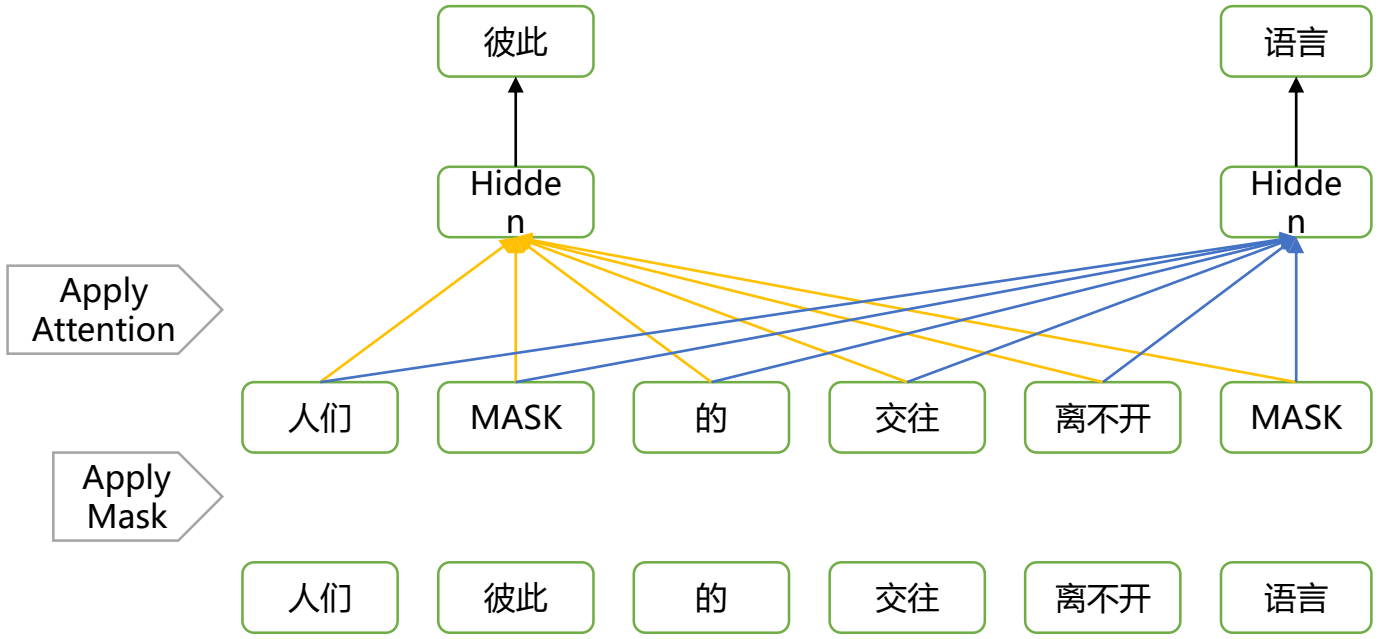

深度学习的模型可以从文本中学到什么?

- 根据不同的语料以及任务，深度学习模型可以从数据中学到不同的内容：
  - 通用文本：句法结构、pos、词共现，层级关系等。
    - (Blevins et al., ACL 2018; Zhang & Bowman, 2018)
    - (Peters et al., NAACL 2018; EMNLP 2018)
  - 诗句：格律、节奏
    - (Lau et al., ACL 2018)
  - 结构化文本：格式、规则
    - (Yin and Neubig, ACL 2017)

from Sebastian Ruder ’s slide

大纲

- Part 1 语言模型简介
  - 文本表征
  - 语言模型
  - 深度学习与语言模型

- Part 2 BERT解析
  - BERT的基本结构
  - 模型模块详解
  - 源码中的细节

- Part 3 应用
  - 如何使用预训练模型
  - 实验心得

BERT的整体结构

- Embedding
  - Word embedding
  - Position embedding
  - Type embedding

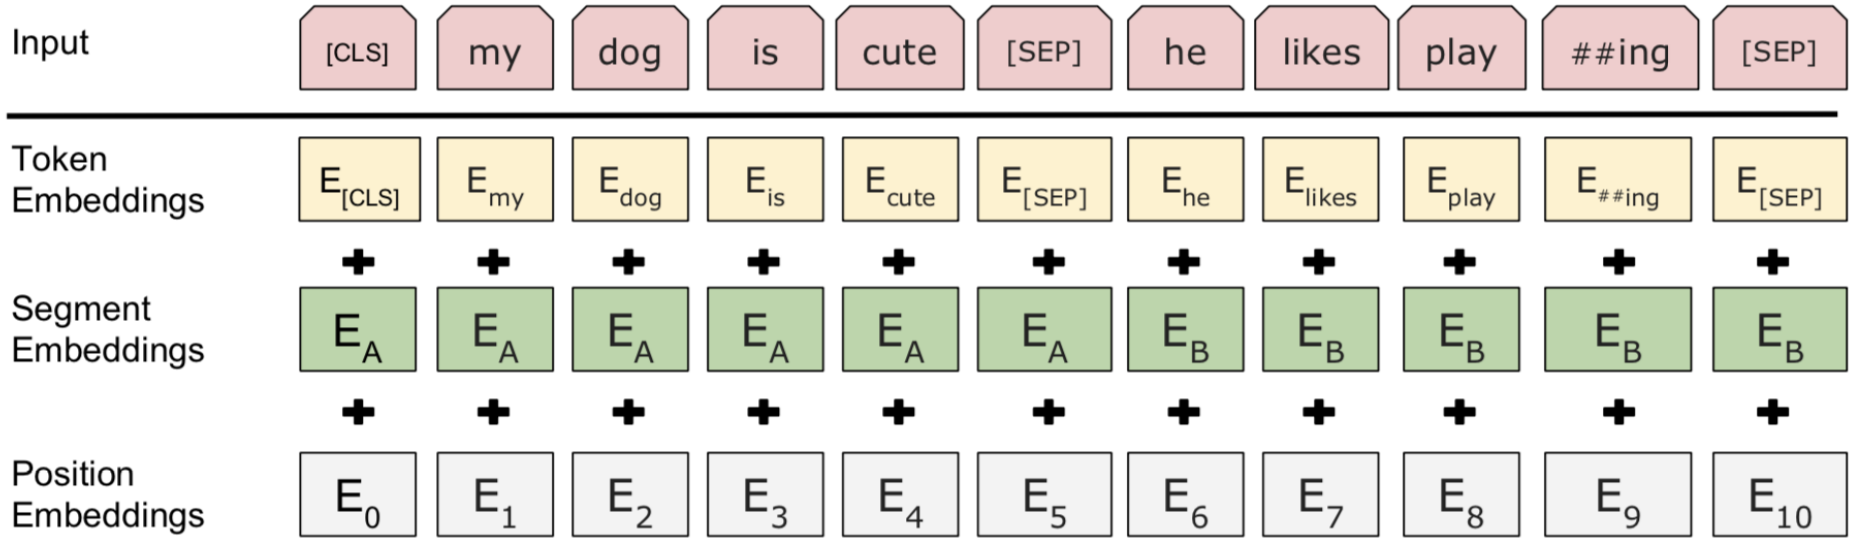

BERT的整体结构

- Transformer Encoder
  - Multi-Head Attention
  - Feed Forward

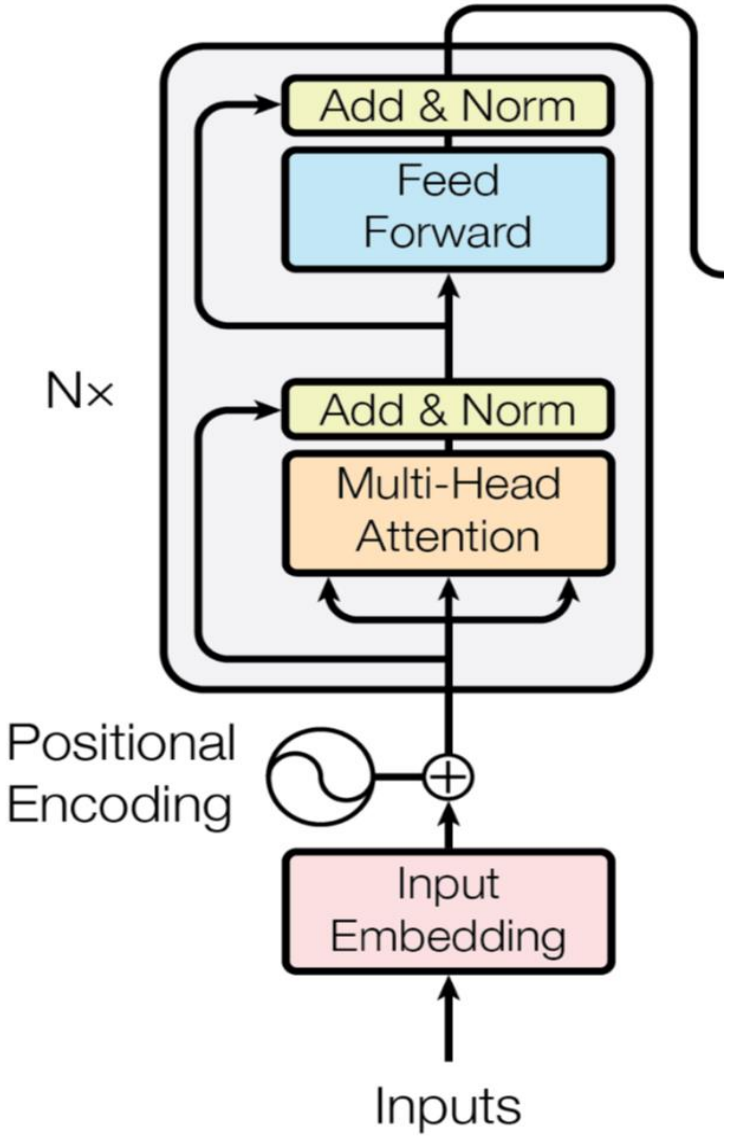

BERT的整体结构

- Losses
  - Mask LM
  - Next sentence prediction

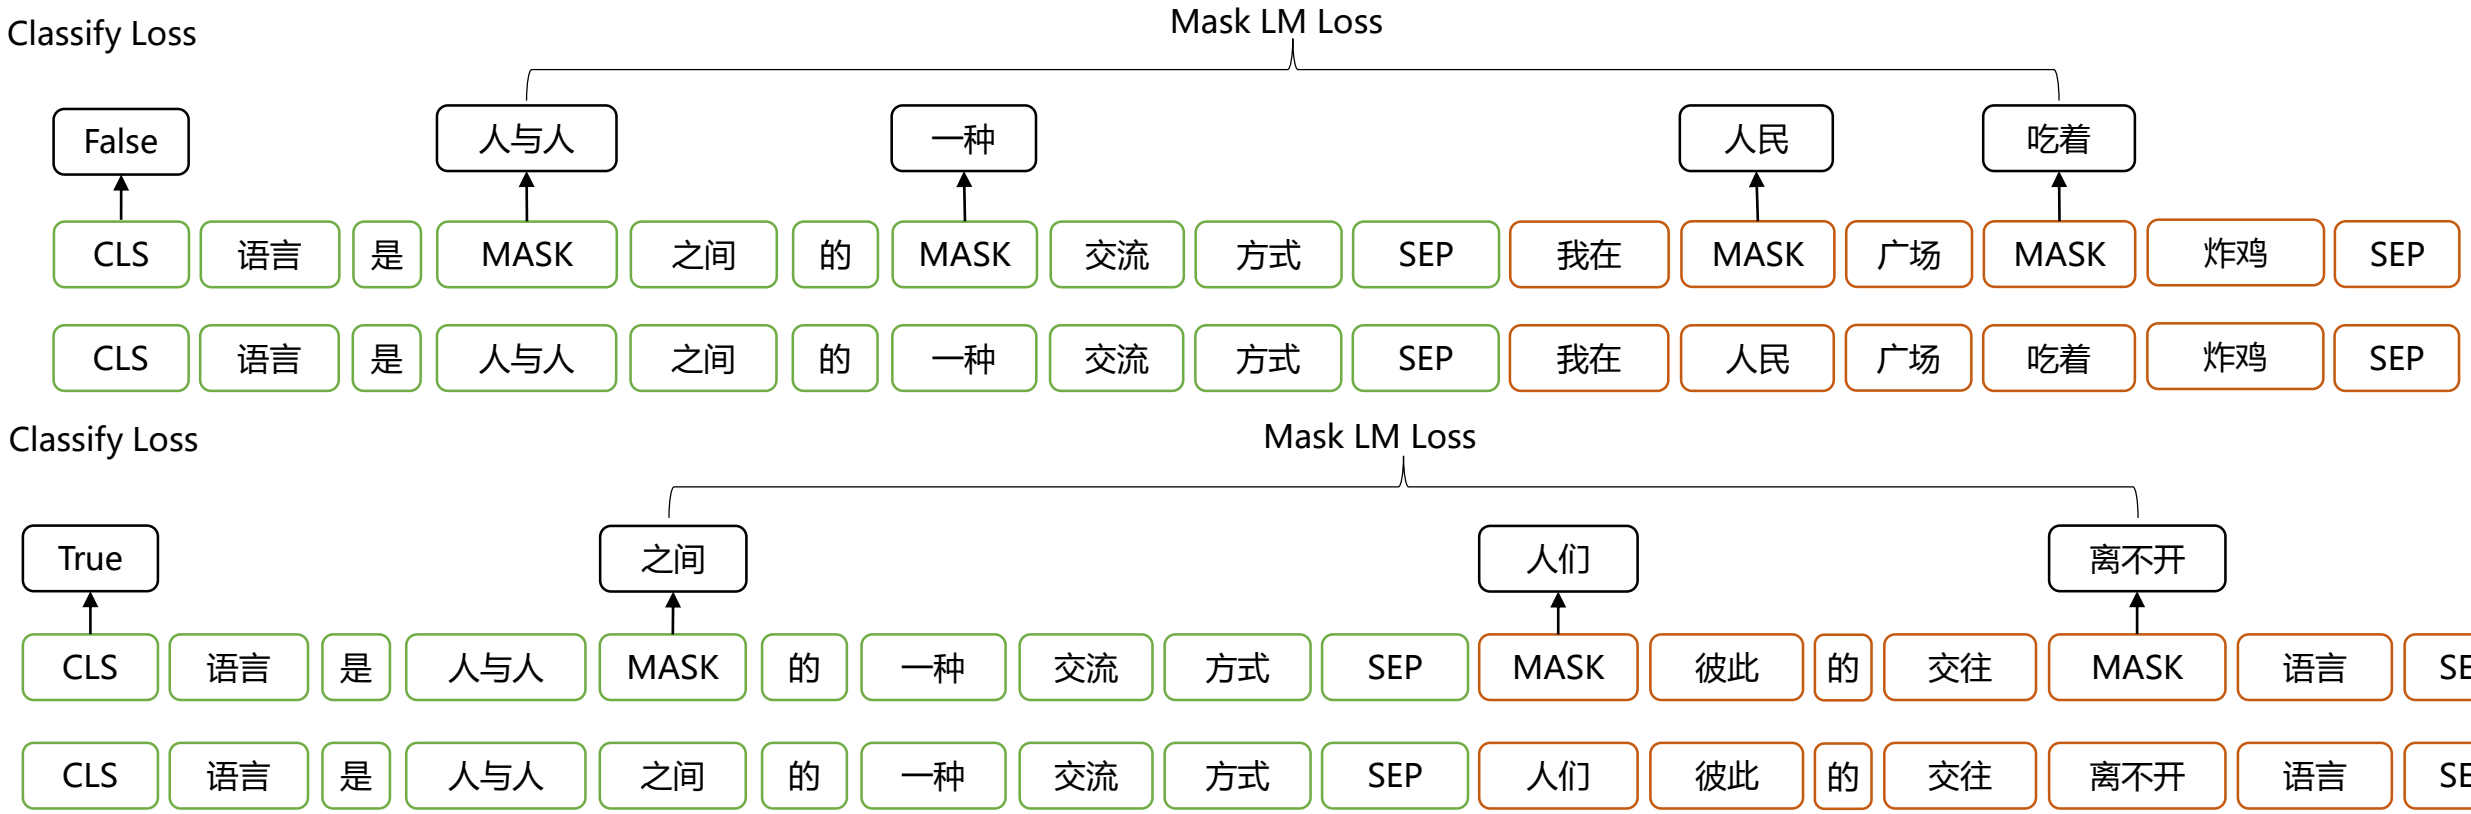

Multi-Head Attention

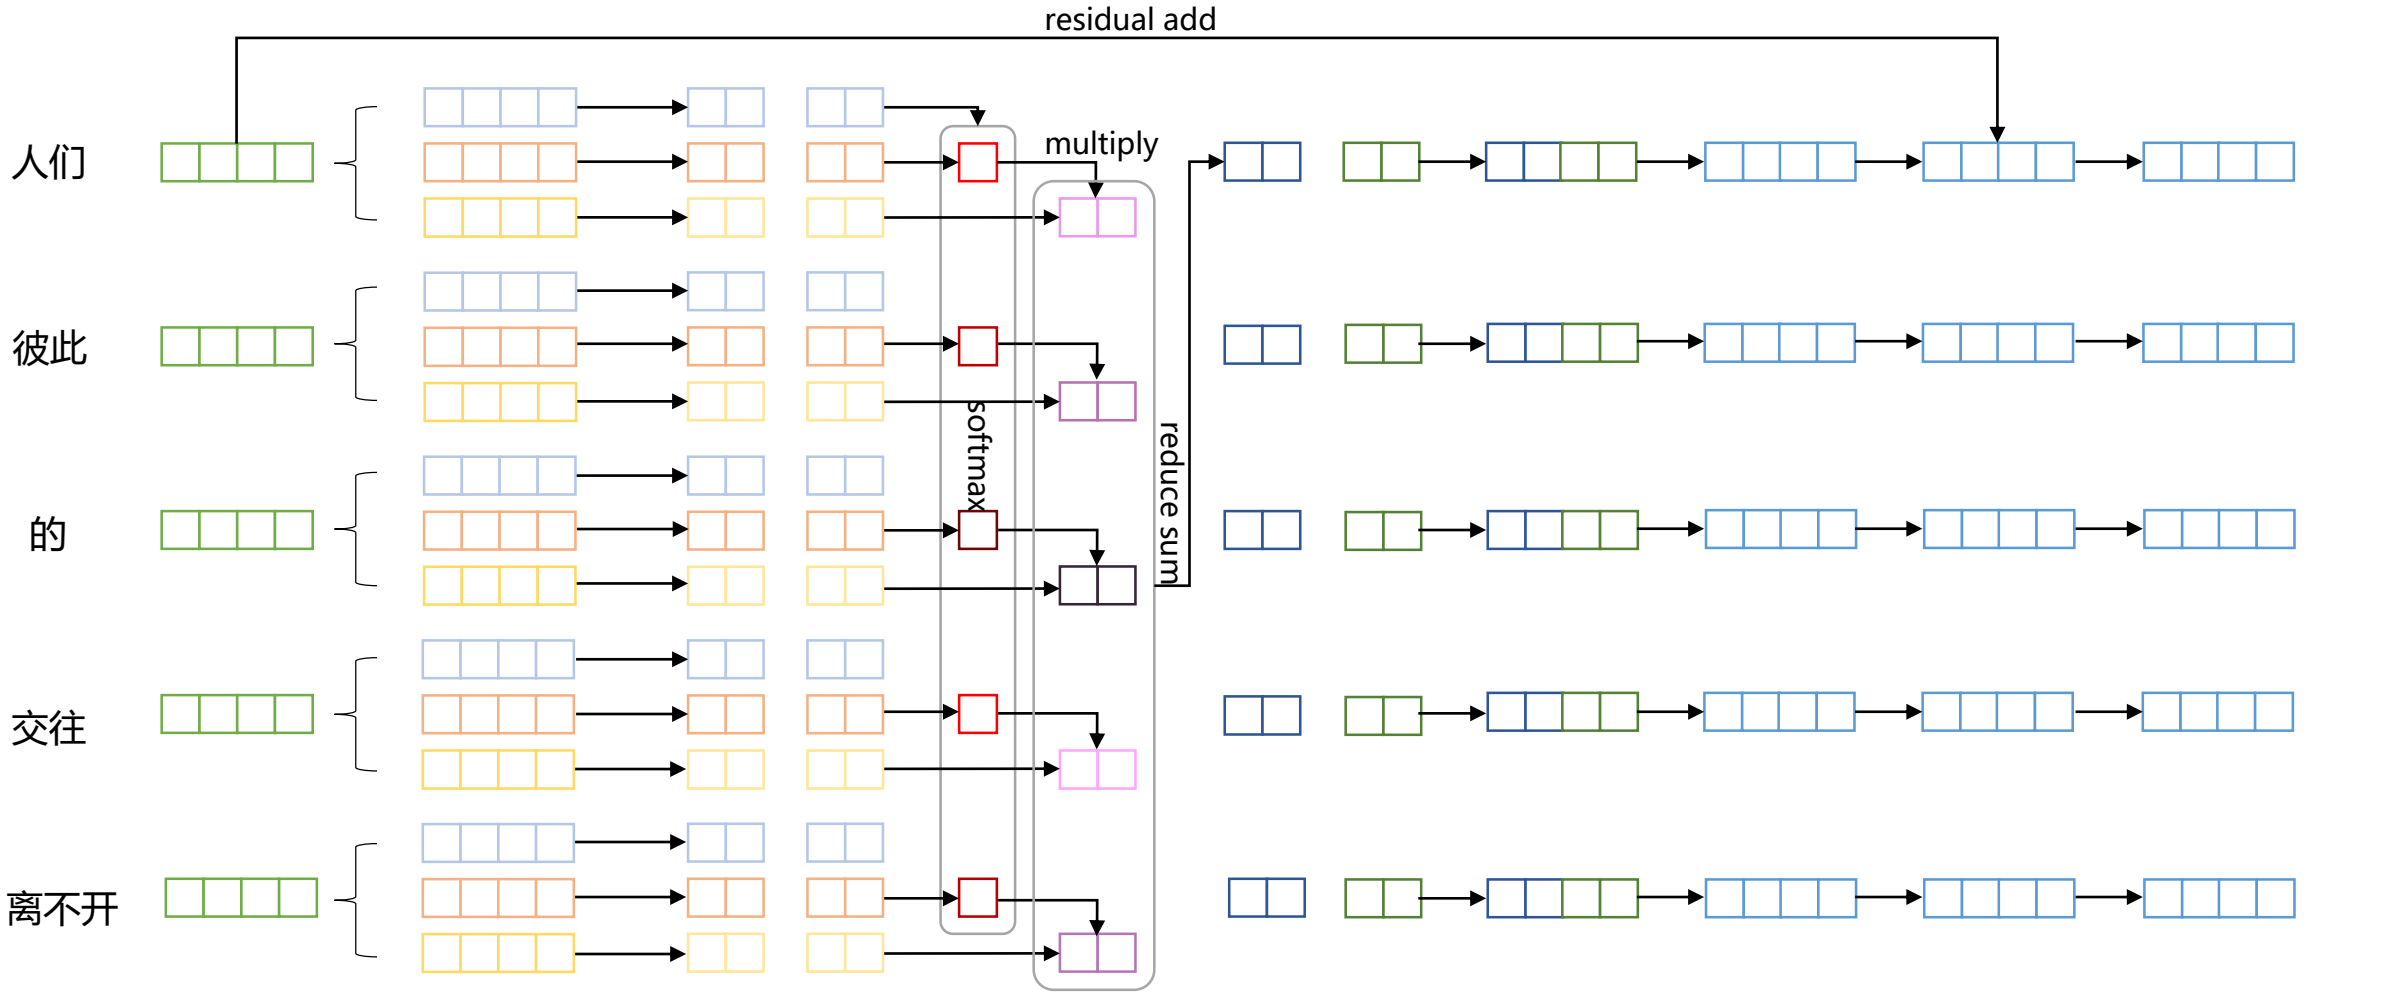

input → Expand → Split heads → Self Attention → Concat heads → Dropout → Residual → Layer Norm

Feed Forward

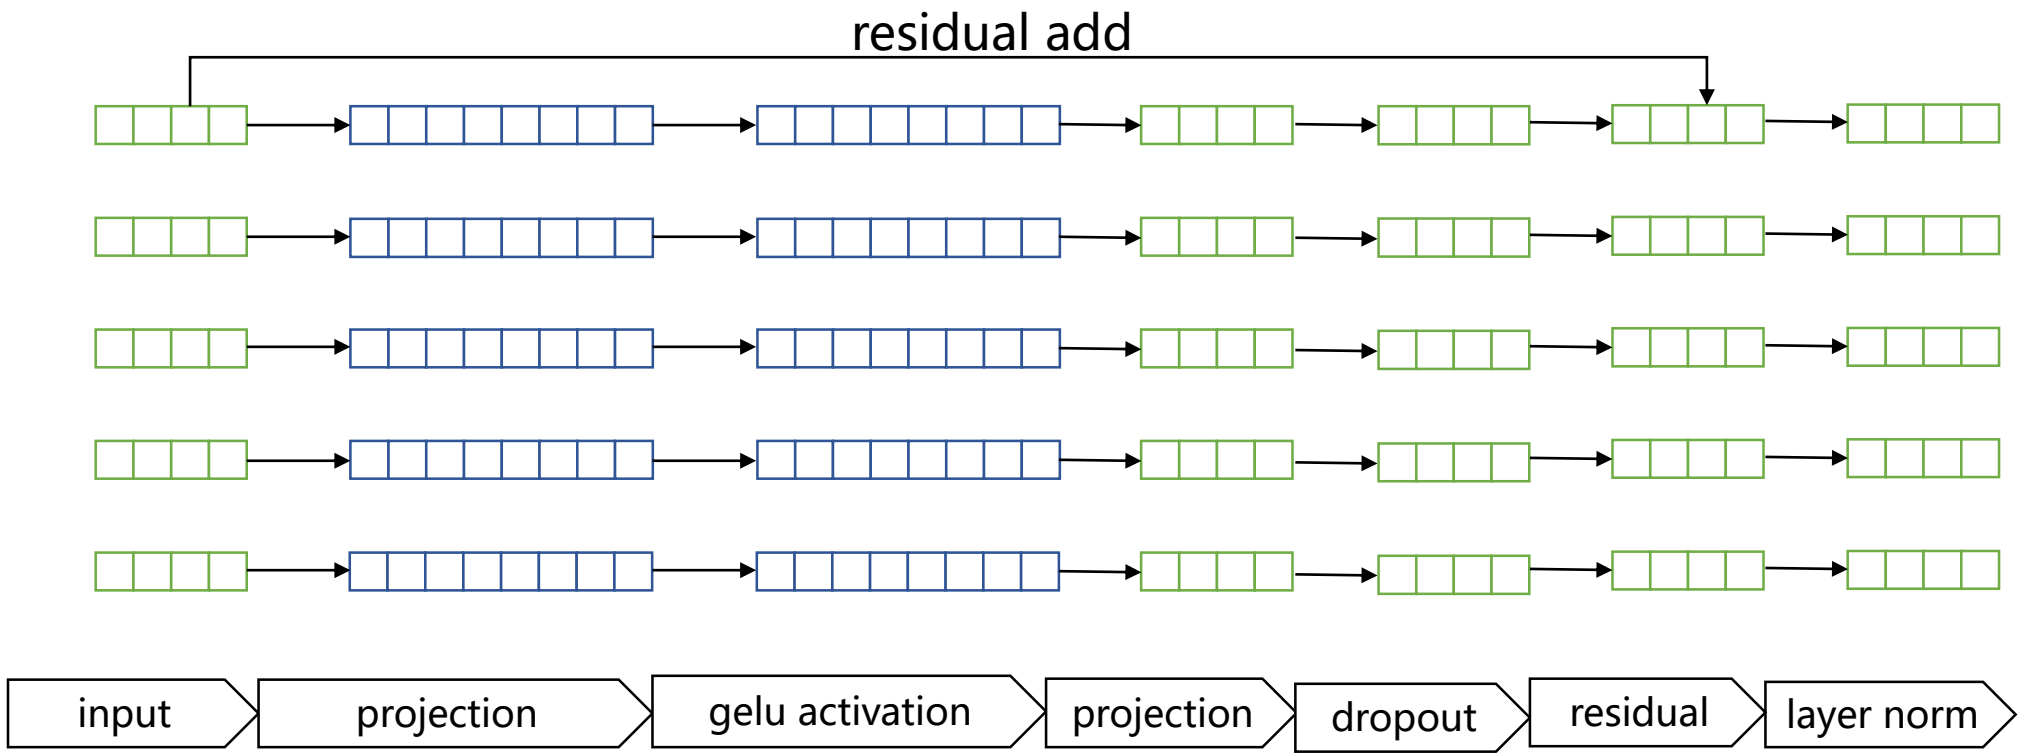

Fine tuning方式

- 文本对分类任务

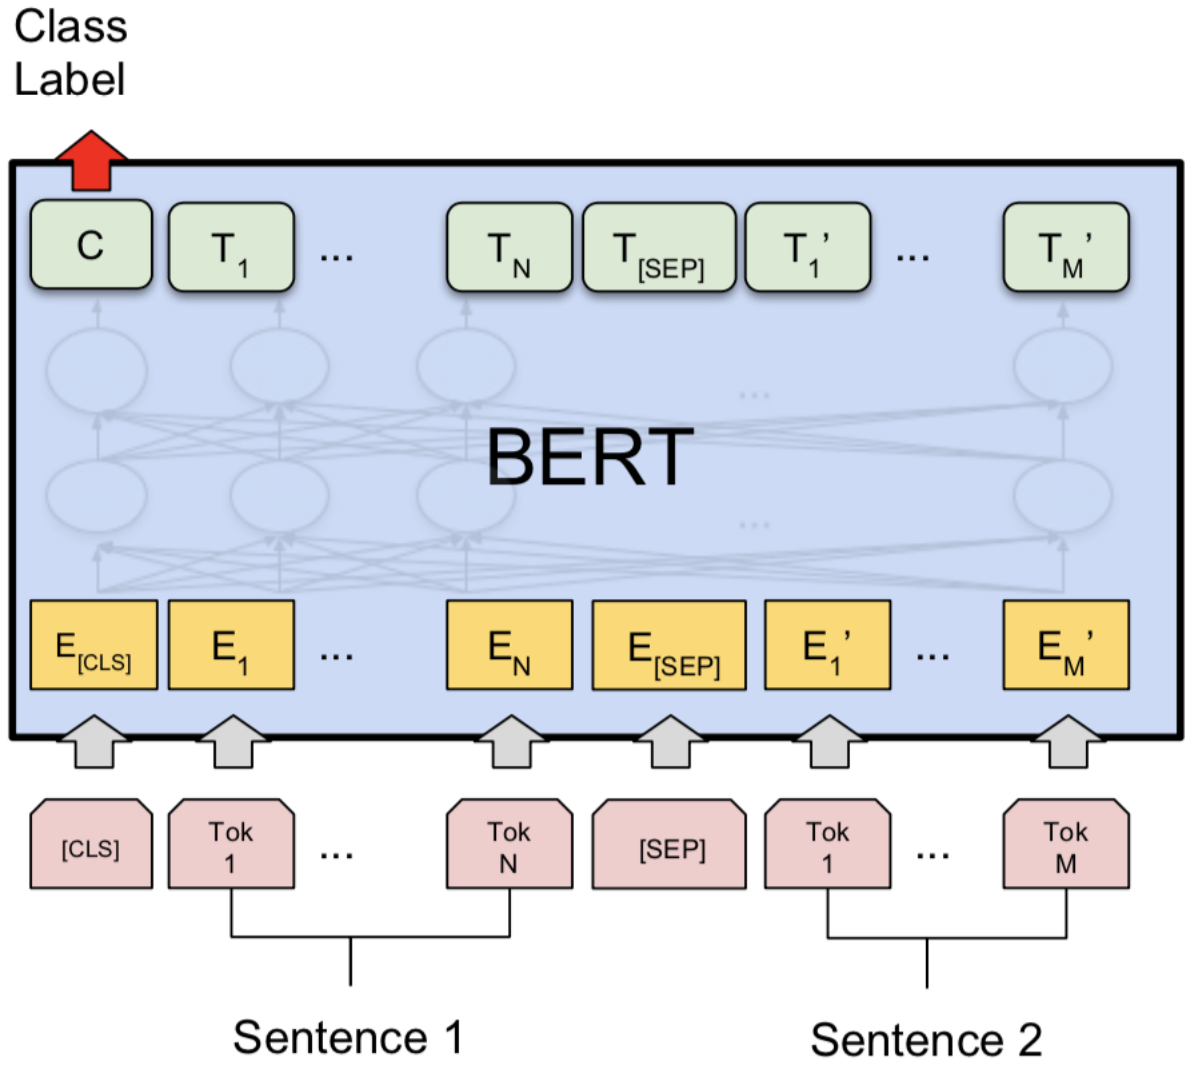

Fine tuning方式

- 文本对分类任务
- 文本分类任务

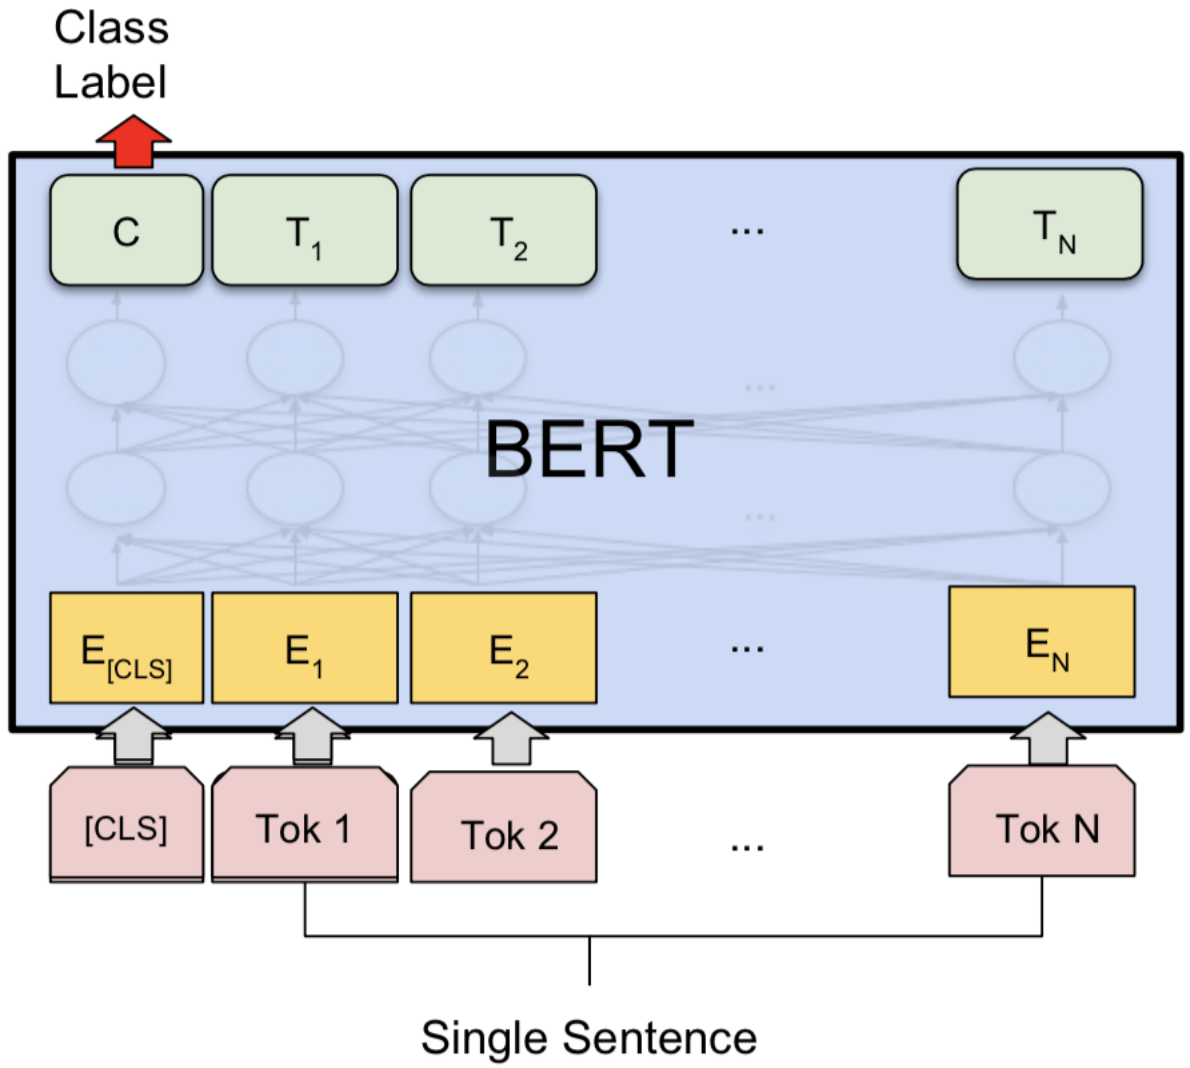

Fine tuning方式

- 文本对分类任务
- 文本分类任务
- QA任务

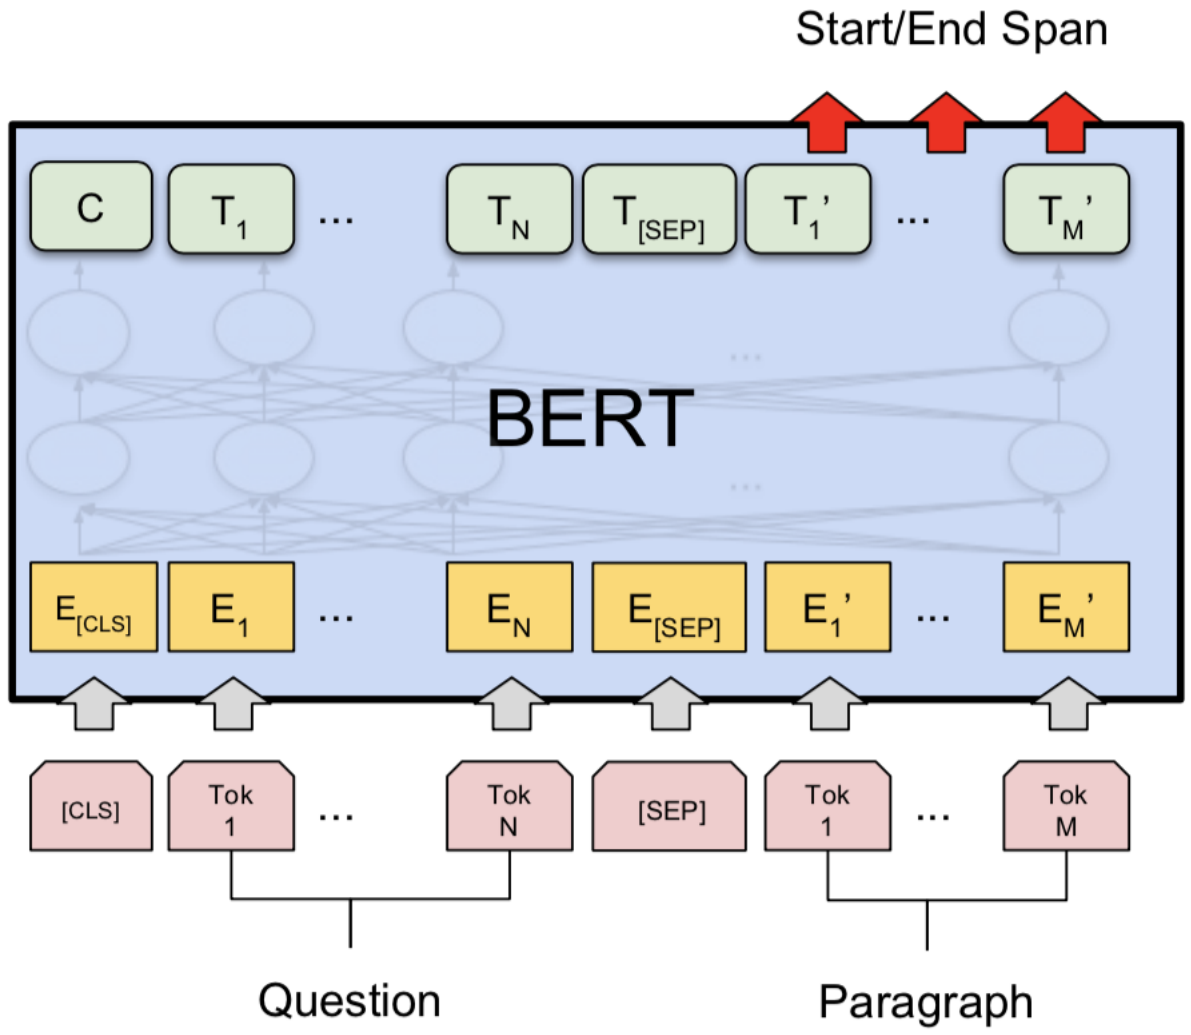

Fine tuning方式

- 文本对分类任务
- 文本分类任务
- QA任务
- 文本Tagging任务

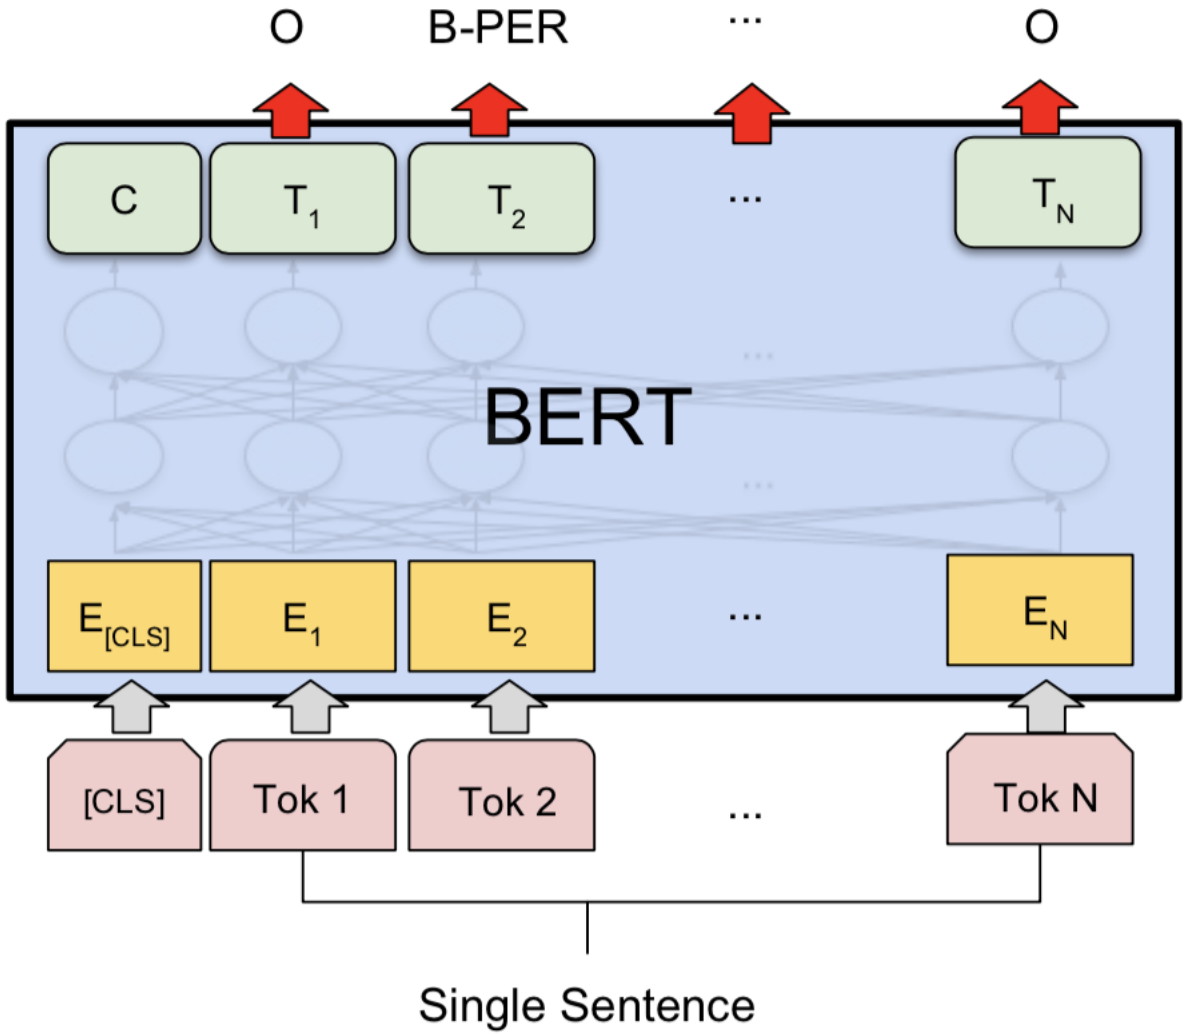

一些细节

- 预训练数据的构建
  - 输入的两个部分都是包含完整句子
  - 同一句中不会同时Mask同一个词
  - 非连续的句子都是取自不同文档
  - 有一定的概率让输入的有效文本长度小于输入全长（利用padding补齐）
  - 对于超过全长的文本，随机从第一部分部分和第二部分部分的头和尾削减

- 模型
  - Encoder LM任务的输出后经过一个gelu非线性层再进行LM Loss的计算；
  - Classify任务的输出后经过一个tanh非线性层再进行的二分类

大纲

- Part 1 语言模型简介
  - 文本表征
  - 语言模型
  - 深度学习与语言模型

- Part 2 BERT解析
  - BERT的基本结构
  - 模型模块详解
  - 源码中的细节

- Part 3 应用
  - 如何使用预训练模型
  - 实验心得

预训语言模型探索

- 语言模型可以用来做什么？
  - 重排：ASR，生成等

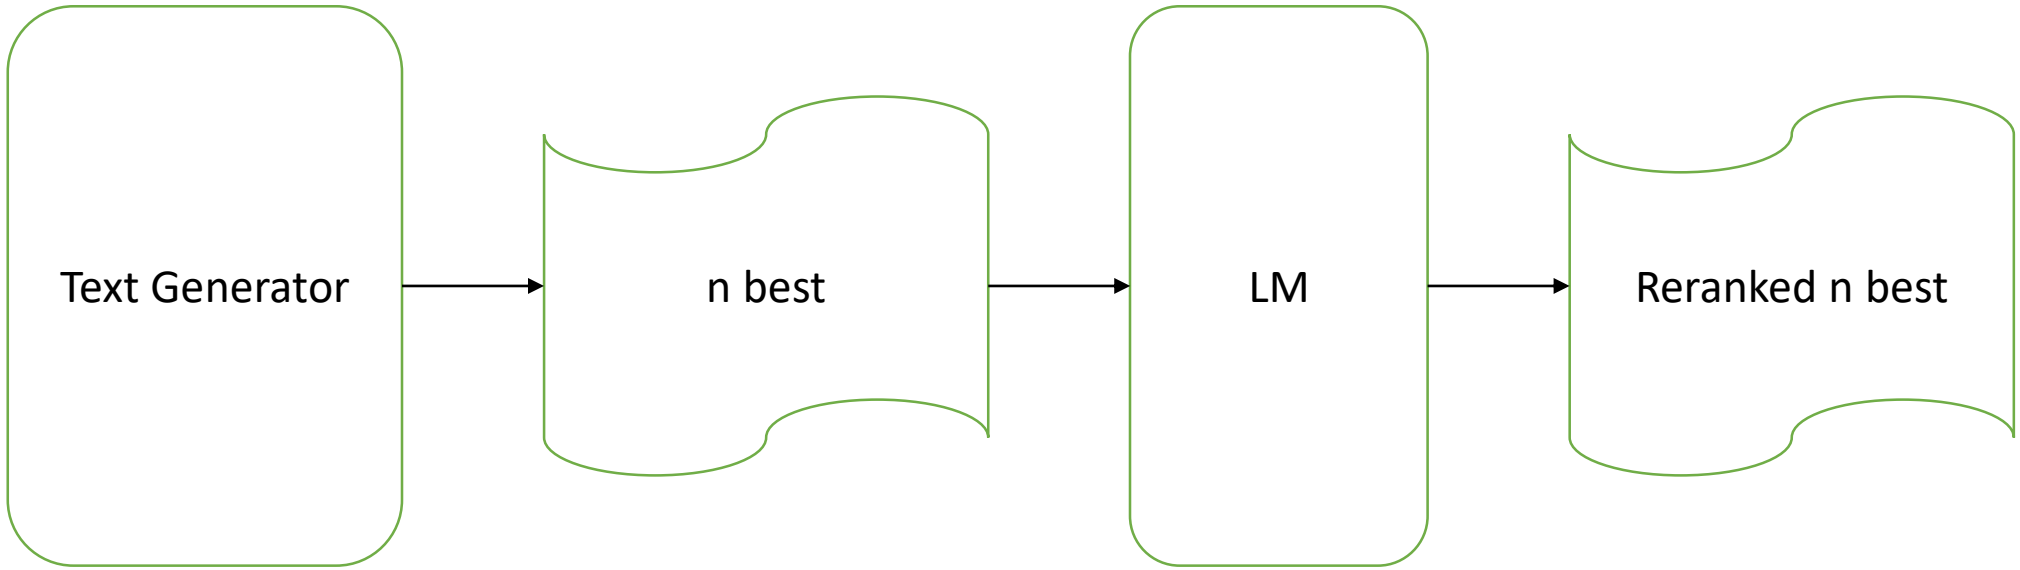

预训语言模型探索

- 语言模型可以用来做什么?
  - 重排：ASR，生成等
  - 迁移：ELMo, GPT, BERT

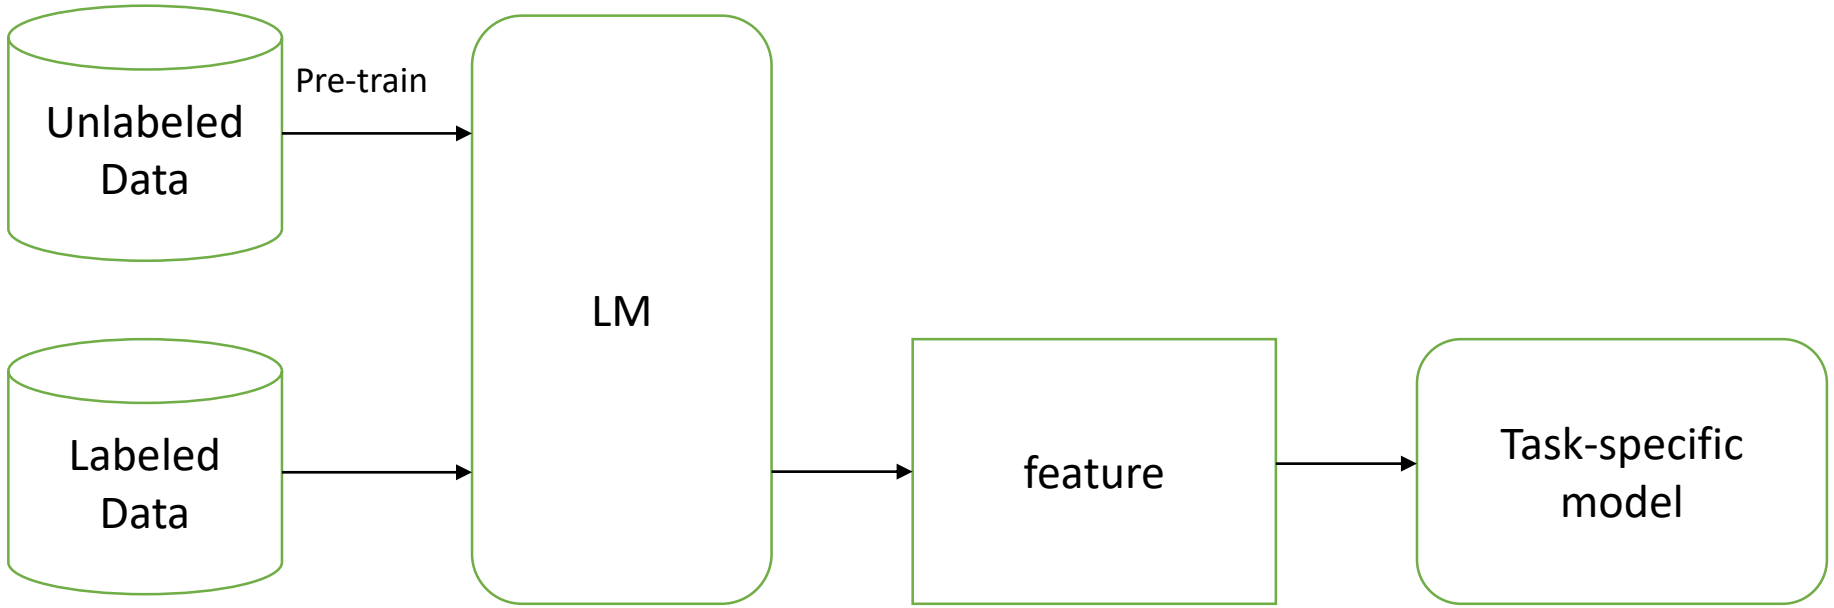

论文中结果

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	89.3	-	-	-
CAFE [58] (5x)	80.2	79.0	89.3	-	-	-
Stochastic Answer Network [35] (3x)	80.6	80.1	-	-	-	-
CAFE [58]	78.7	77.9	88.5	83.3		
GenSen [64]	71.4	71.3	-	-	82.3	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	**61.7**
Finetuned Transformer LM (ours)	**82.1**	**81.4**	**89.9**	**88.3**	**88.1**	56.0

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	**Average** -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.9	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	88.1	91.3	45.4	80.0	82.3	56.0	75.2
$\text{BERT}_{\text{BASE}}$	84.6/83.4	71.2	90.1	93.5	52.1	85.8	88.9	66.4	79.6
$\text{BERT}_{\text{LARGE}}$	**86.7/85.9**	**72.1**	**91.1**	**94.9**	**60.5**	**86.5**	**89.3**	**70.1**	**81.9**

实验观察

- Elmo
  - 百度百科+中文维基，18亿tokens
  - batch size: 64, length:128, 256
- GPT
  - 18亿tokens
  - batch size: 24, length:128, 256
- BERT(实验)
  - 1亿tokens
  - batch size: 32, length:512

实验观察

- 一些观察
  - 在QA任务上效果明显
  - 在短文本分类上效果不及预期
  - BERT在不按完整句子构建span时不按完整句子构建span
    - 预测是否连续的任务收敛很快
    - 短句很多的时候ppl收敛会慢

Q&A

追一科技公众号

追一招聘公众号